Gestión de incertidumbre y alucinaciones en LLMs clínicos

Resumen conceptual preparado para reunión. Explicado de forma clara, técnica y fácil de transmitir oralmente.

La idea principal del enfoque es que un sistema clínico basado en LLMs no debería evaluarse únicamente por su exactitud media. El problema realmente importante es cómo gestiona la incertidumbre, cómo verifica la evidencia y cómo decide cuándo puede responder de forma autónoma y cuándo debería abstenerse o escalar el caso a supervisión humana.

1. Factualidad vs fidelidad al contexto

El trabajo diferencia dos conceptos que normalmente se mezclan. La factualidad pregunta si una afirmación es verdadera en términos generales. La fidelidad al contexto pregunta si esa afirmación está realmente apoyada por el documento concreto que el sistema está utilizando. Esto es importante porque un modelo puede responder algo médicamente correcto, pero que no esté respaldado por el abstract o el caso clínico concreto.

2. Tipos de alucinación

La alucinación intrínseca ocurre cuando el modelo contradice directamente el contexto fuente. Por ejemplo, cuando el abstract dice que no hubo mejora y el modelo afirma lo contrario. La alucinación extrínseca ocurre cuando el modelo añade contenido no respaldado por la evidencia disponible. Ese contenido incluso puede sonar razonable o plausible, pero sigue sin estar justificado por el documento.

3. Confianza y calibración

Que un modelo diga que está “muy seguro” no implica que realmente tenga razón. Esa confianza verbalizada es simplemente otra secuencia de texto generada. La calibración busca algo mucho más útil: que las probabilidades emitidas por el sistema coincidan con la frecuencia

real de acierto. Si el sistema asigna una confianza de 0.8, aproximadamente el 80% de casos similares deberían ser correctos.

4. Incertidumbre aleatoria y epistémica

La incertidumbre aleatoria aparece cuando la propia evidencia es ambigua o insuficiente incluso para expertos humanos. La incertidumbre epistémica aparece cuando el problema está en el sistema: falta de conocimiento, dataset shift, mala adaptación al dominio clínico o limitaciones del modelo.

5. Señales white-box

Las señales white-box utilizan información interna del modelo, como logits, probabilidades de tokens o entropía. La entropía mide cuánto duda el modelo entre varias continuaciones posibles. Cuanto más repartida está la distribución de probabilidad, mayor es la incertidumbre interna. Estas señales sirven como sensores internos del comportamiento del modelo, aunque no garantizan que una respuesta sea verdadera.

6. Señales black-box

Las señales black-box no necesitan acceso interno al modelo. Solo utilizan las entradas y salidas generadas. Esto es especialmente útil cuando se trabaja con APIs cerradas. Aquí entran técnicas como autoconfianza verbalizada, muestreo múltiple o consistencia entre respuestas.

7. SelfCheck y consistencia

SelfCheck parte de una idea muy intuitiva: si el modelo realmente dispone de una base sólida para responder, distintas generaciones deberían ser consistentes entre sí. Si las respuestas cambian mucho entre generaciones, eso puede indicar incertidumbre o posibles alucinaciones. Aun así, consistencia no significa necesariamente verdad. Un modelo puede equivocarse de forma muy consistente.

8. Semantic entropy

La semantic entropy intenta medir incertidumbre semántica, no únicamente diferencias superficiales de redacción. La idea es agrupar respuestas que significan lo mismo aunque usen palabras distintas. Si aparecen muchos significados incompatibles entre generaciones, la entropía semántica aumenta. En este enfoque se usa una aproximación más ligera basada en similitud léxica y clustering aproximado.

9. NLI (Natural Language Inference)

NLI es una técnica de verificación entre una afirmación y un documento fuente. El objetivo es decidir si el documento: apoya la afirmación, la contradice, o no permite concluir nada. Esto es importante porque una frase puede sonar perfectamente plausible y aun así no estar respaldada por el abstract. En este trabajo se usa una aproximación heurística basada en similitud, negaciones y conflictos numéricos, en lugar de un modelo NLI profundo completo.

10. Claims atómicos y verificación

En lugar de verificar toda la respuesta como un único bloque, el sistema puede dividirla en afirmaciones pequeñas o claims. Después, cada claim se verifica individualmente frente a la evidencia disponible. Esto permite detectar contradicciones, omisiones y afirmaciones no soportadas de forma mucho más granular.

11. Predicción selectiva

El sistema no está obligado a responder siempre. Tras calcular señales de incertidumbre y verificación, puede: aceptar la respuesta, abstenerse, o escalar el caso a supervisión humana. El objetivo no es construir un modelo “perfecto”, sino un sistema capaz de gestionar el riesgo de forma razonable y trazable.

12. Pipeline general

El pipeline completo sigue una arquitectura modular: • Entrada: pregunta + contexto documental. • El LLM genera una respuesta. • Se extraen etiqueta, rationale y evidencia. • Se calculan

señales de incertidumbre y grounding. • Se agregan en un score de riesgo. • Finalmente se aplica una política selectiva: aceptar, abstenerse o escalar a humano. La idea importante es separar claramente generación, verificación y toma de decisión.

Conclusión La idea central del trabajo es que las alucinaciones en modelos clínicos no deben tratarse únicamente como errores de texto. El problema real es cómo gestionar incertidumbre, grounding, verificación y riesgo operacional en sistemas capaces de intervenir en contextos de alto impacto.