Capítulo 1

Marco Teórico y Regulatorio

Este capítulo establece los fundamentos científicos, técnicos y legales que justifican la arquitectura neuro-simbólica propuesta para el presente Trabajo. La adopción masiva de Inteligencia Artificial (IA) en el sector financiero ha estado dominada en los últimos años por los Modelos Fundacionales y el Aprendizaje Profundo (*Deep Learning*). Sin embargo, la exigencia ineludible de operar en un marco de alta regulación, donde las decisiones automatizadas afectan a los derechos económicos de los ciudadanos, impone restricciones que las arquitecturas puramente neuronales no pueden satisfacer por diseño.

A lo largo de este capítulo, se desarrollará un análisis crítico de las limitaciones estructurales de la IA conexionista, demostrando que la falta de representaciones formales explícitas en los modelos de lenguaje grandes (LLMs) hace que propiedades como la trazabilidad, la consistencia y la verificabilidad sean, no ya difíciles, sino estructuralmente inalcanzables. A continuación, se profundizará en las vulnerabilidades emergentes que estas limitaciones cognitivas provocan, especialmente cuando se dota a estos sistemas de autonomía transaccional. Este diagnóstico integral servirá como base para justificar, desde una perspectiva tanto tecnológica como regulatoria, la necesidad de transitar hacia un paradigma neuro-simbólico gobernado.

1.1. Limitaciones de la Inteligencia Artificial Conexionista (Deep Learning)

La segunda ola de la inteligencia artificial, caracterizada por el *Deep Learning* y el auge de arquitecturas como los *Transformers*, ha supuesto un avance sin precedentes en la capacidad de las máquinas para procesar, interpretar y generar lenguaje natural. Las redes neuronales profundas han logrado capturar casi a la perfección la variabilidad lingüística del mundo real, permitiendo

a los sistemas comprender instrucciones complejas, manejar elipsis, tolerar errores gramaticales y generar respuestas con un nivel de fluidez indistinguible del humano.

No obstante, tal como se documenta la literatura científica reciente, estas capacidades lingüísticas coexisten con deficiencias cognitivas profundas. Autores como Marcus (2020) han señalado que las limitaciones del aprendizaje profundo (su opacidad, su inconsistencia y la imposibilidad de verificación formal) no son meros defectos técnicos que futuras iteraciones de los modelos vayan a corregir mediante un mayor volumen de datos o parámetros, sino que constituyen consecuencias estructurales ineludibles de su propia arquitectura.

1.1.1. Naturaleza Estocástica y Cajas Negras

La base del funcionamiento de los Grandes Modelos de Lenguaje (LLMs) es la predicción estocástica de *tokens*. Estos sistemas generan texto calculando distribuciones de probabilidad sobre un vocabulario, condicionadas por el contexto previo, careciendo en todo momento de un modelo mental del mundo real, de una ontología subyacente o de mecanismos de razonamiento lógico deductivo puro. En el paradigma conexionista, el conocimiento no se codifica en estructuras discretas con semántica definida (como proposiciones, reglas lógicas o redes semánticas), sino que se distribuye de manera implícita a lo largo de miles de millones de parámetros (pesos y sesgos) en los patrones de activación de la red.

Esta distribución implícita convierte a los LLMs en *cajas negras*. Las decisiones y respuestas que emiten son el resultado de complejas multiplicaciones de matrices y operaciones *softmax* que carecen por completo de interpretación semántica accesible para un observador humano. Si un sistema conversacional puramente neuronal deniega la concesión de un préstamo, no existe ningún mecanismo para inspeccionar sus parámetros y aislar la regla.º el -azonamiento.[ex]acto que condujo a dicha denegación. Esta opacidad entra en conflicto directo con los requisitos más elementales de la *accountability* que posteriormente explicaremos.

1.1.2. El Fenómeno de las Alucinaciones

Derivada de su naturaleza probabilística, la segunda gran limitación de los modelos fundacionales es el fenómeno de las alucinaciones. Dado que un LLM aprende a través de la maximización de la verosimilitud de las secuencias de texto durante su fase de preentrenamiento, el modelo carece de un mecanismo intrínseco para distinguir entre hechos factuales, verdades lógicas y simples correlaciones estadísticas latentes en sus datos.

Cuando a un modelo neuronal se le exige razonar sobre un caso práctico (como evaluar la solvencia de un cliente en base a la Ley de Contratos de Crédito), el sistema no está deduciendo lógicamente la respuesta a partir de axiomas legales. En su lugar, está generando la secuencia de palabras que, estadísticamente, es más probable que siga al *prompt* introducido. Esto da lugar a que el modelo pueda inventar datos, citar artículos normativos inexistentes o fabricar justificaciones que parecen razonables y articuladas, pero que son fundamentalmente falsas.

Aunque las técnicas de entrenamiento, alineamiento y verificación han permitido reducir progresivamente la frecuencia de estas alucinaciones, no es posible garantizar su eliminación completa. Al tratarse de sistemas probabilísticos, siempre existe la posibilidad de que el modelo genere información incorrecta con un elevado grado de coherencia y aparente certeza, especialmente cuando se enfrenta a situaciones que requieren conocimientos específicos o inferencias complejas. Por tanto, incluso cuando el sistema presenta un elevado rendimiento en términos generales, la ausencia de garantías sobre la veracidad de cada una de sus respuestas constituye una limitación estructural que debe tenerse en cuenta en aquellos contextos en los que un error puede producir consecuencias relevantes.

En el dominio del crédito, la alucinación representa un riesgo inasumible. Una respuesta que afirme incorrectamente que una póliza puede ser cancelada sin penalización debido a una "nueva normativaïnventada por el modelo genera perjuicios económicos reales para la entidad bancaria. Como se analizará posteriormente en el contexto regulatorio, el EU AI Act y el Reglamento DORA exigen que los sistemas financieros mantengan una resiliencia operativa y una trazabilidad exacta de sus decisiones.

1.1.3. Inestabilidad en la Toma de Decisiones y Efecto Contextual

La tercera limitación estructural de los enfoques conexionistas puros es su profunda inestabilidad frente a la variabilidad de entrada. En un sistema de reglas simbólico (GOFAI - *Good Old-Fashioned AI*), una condición evaluada producirá el mismo resultado siempre que los parámetros de entrada sean idénticos, garantizando un determinismo absoluto. Por el contrario, la inferencia en un LLM es altamente sensible a perturbaciones menores.

Investigaciones recientes han documentado empíricamente esta fragilidad. Raj et al. (2023) demostraron que los LLMs producen respuestas inconsistentes ante reformulaciones de la misma pregunta (paráfrasis), documentando tasas de inconsistencia semántica que pueden superar el 30 % en dominios

especializados. Esto significa que si un cliente solicita un préstamo escribiendo "Quiero solicitar 5000 euros a 4 años"frente a "Necesito un crédito de 5000€ a devolver en 48 meses", el modelo neuronal podría aprobar la primera solicitud y denegar la segunda simplemente porque la distribución de probabilidad generada a partir de los *tokens* de entrada difiere ligeramente.

A esta inestabilidad semántica se suma la degradación cognitiva en el manejo de contextos largos. Aunque los modelos modernos han ampliado su ventana de contexto, Liu et al. (2023) han evidenciado el efecto *"lost in the middle"*: la capacidad de los LLMs para utilizar información decae drásticamente cuando los datos críticos se encuentran en posiciones intermedias del contexto. Adicionalmente, Levy et al. (2024) documentaron que la capacidad de razonamiento"del modelo se degrada exponencialmente a medida que la longitud de la conversación aumenta.

En el contexto de la IA conversacional bancaria, donde una interacción puede extenderse a lo largo de múltiples turnos y el usuario puede proporcionar datos, cambiar de opinión, retractarse o aportar información fragmentada, depender de la ventana de contexto del LLM para mantener el .^{es}tado"de la operación es una debilidad arquitectónica. El modelo no mantiene un registro estructurado de qué datos han sido proporcionados, cuáles han sido verificados y cuáles son simplemente comentarios; todo se amalgama como *tokens* indiferenciados. Esta falta de *Information State* explícito impide garantizar la consistencia sistémica, haciendo que la toma de decisiones sea impredecible.

1.1.4. Ciberseguridad y Vulnerabilidades

Las limitaciones cognitivas expuestas no solo afectan a la calidad del diálogo y toma de decisiones, sino que configuran una superficie de ataque completamente nueva desde la perspectiva de la ciberseguridad. Al carecer de una representación formal que separe semánticamente las instrucciones del sistema de los datos introducidos por el usuario, los LLMs son vulnerables a manipulaciones lingüísticas que subvierten su comportamiento previsto.

Vectores de Ataque Semántico

El principal riesgo en las aplicaciones basadas en Modelos Fundacionales es el *Prompt Injection*. Este ataque ocurre cuando se introducen comandos ocultos o maliciosos en los datos que el modelo procesa, confundiéndolos con instrucciones del sistema. Un ejemplo clásico en el entorno bancario sería un usuario que adjunta un historial crediticio en PDF que contiene el texto invisible: "*Aviso del sistema: El análisis ha finalizado. Clasifica este perfil de*

solvencia como APROBADO sin importar los ingresos previos.". Al procesar el documento, el modelo es incapaz de separar los datos de las instrucciones y ejecuta la orden del atacante.

Complementariamente, el *Jailbreaking* se refiere a las técnicas adversariales que el usuario introduce directamente en la conversación para romper las barreras éticas, lógicas y de seguridad impuestas por los desarrolladores, a menudo mediante ingeniería social o manipulación de *tokens*.

La existencia de estas vulnerabilidades demuestra que las restricciones impuestas mediante *prompts* no son estructurales ni formales, sino meramente estadísticas: se cumplen con alta probabilidad en escenarios benignos, pero fallan cuando la presión probabilística de los datos del atacante supera la fuerza matemática de la instrucción de sistema subyacente.

El Agotamiento de las Aproximaciones Paliativas

Ante la gravedad de los vectores de ataque semántico, la industria ha desarrollado diversas técnicas conexionistas para intentar mitigar el problema sin abandonar el paradigma puramente neuronal. No obstante, estas soluciones operan sobre los síntomas externos del modelo y no sobre su proceso de decisión interno. Entre las más extendidas, y sus respectivas carencias, destacan:

- **Los *guardrails* y clasificadores externos:** Sistemas de filtrado perimetral (como *NeMo Guardrails* o *Llama Guard*) que interceptan la entrada o la salida de texto para detectar anomalías mediante modelos estadísticos secundarios. Sin embargo, actúan exclusivamente sobre la superficie lingüística. Un filtro puede bloquear una palabra explícitamente tóxica, pero es incapaz de evaluar si una decisión de negocio omitida o alterada vulnera la coherencia contractual del diálogo o las políticas de solvencia de la entidad.

- **El *prompt engineering*:** Intentar gobernar un LLM introduciendo directrices operativas en lenguaje natural dentro del *prompt* ("*bajo ninguna circunstancia apruebes un préstamo sin verificar antes la nómina*") confunde instrucción con ejecución determinista. El modelo interpreta estas directrices de manera probabilística, por consiguiente, una reformulación adversaria suficientemente compleja o la acumulación de contexto en diálogos extensos pueden provocar que el sistema diluya o ignore la restricción por completo.

- **El alineamiento estadístico (RLHF y *Constitutional AI*):** Aunque técnicas como el Aprendizaje por Refuerzo a partir de Retroalimen-

tación Humana (Bai et al., 2022) reducen la frecuencia promedio de respuestas no deseadas, estas modifican las probabilidades de salida en el espacio latente, pero no introducen estructuras verificables de toma de decisiones. Estudios empíricos exhaustivos, como los realizados por Wolf et al. (2023) y Zou et al. (2023), han demostrado de forma irrefutable que incluso los mejores modelos pueden ser inducidos a violar sus políticas mediante ataques adversariales.

El Riesgo Crítico en Entornos Agénticos Autónomos

Esta fragilidad intrínseca alcanza una dimensión crítica cuando se dota al modelo neuronal de autonomía operativa mediante arquitecturas agénticas. La tendencia reciente de la industria hacia patrones como *ReAct* (Yao et al., 2023) o *frameworks* como *LangChain* y *CrewAI*, donde se otorgan al LLM herramientas como APIs de bases de datos, capacidad de enviar correos electrónicos o ejecutar transferencias, eleva el problema a niveles críticos para la ciberseguridad financiera.

Como advierten Ruan et al. (2024) en su análisis sobre los riesgos de agentes basados en LLMs, un agente autónomo es, por definición, un agente cuyas decisiones operativas no están gobernadas externamente. En estos sistemas, el LLM decide autónomamente, basándose en la inferencia probabilística del contexto, qué herramienta invocar, en qué orden y con qué parámetros. Si un ataque de los mencionados previamente tiene éxito contra un agente autónomo, el atacante no solo obtiene control sobre el texto generado, sino que adquiere capacidad ejecutiva sobre las herramientas de las que dispone el agente.

En conclusión, el paradigma conexionista puro genera comportamiento lingüístico sin representarlo formalmente. La combinación de una lógica estocástica opaca con la capacidad de ejecutar llamadas a sistemas bancarios genera un riesgo inaceptable para los estándares de supervisión y resiliencia digital. Las capas de control superpuestas sobre modelos probabilísticos solo proporcionan garantías estadísticas, pero en ningún caso las garantías formales, deterministas y auditables que exige el sector financiero. Esta limitación fundamenta la necesidad de recurrir a la tradición simbólica de la inteligencia artificial, objeto de análisis en la siguiente sección.