# Índice general


**1. Marco Teórico y Estado del Arte** **3**
- 1.1. El Paradigma de la Accountability y el Marco Regulatorio . . 3
  - 1.1.1. De la Transparencia a la Accountability . . . . . 4
  - 1.1.2. Explicabilidad Post-Hoc vs. Explicabilidad Constitutiva 5
  - 1.1.3. Marco Regulatorio y Derecho a Explicación . . . . . 5
- 1.2. Inteligencia Artificial Conexionista (Deep Learning) . . . . . 7
  - 1.2.1. Naturaleza Estocástica y Cajas Negras . . . . . 8
  - 1.2.2. El Fenómeno de las Alucinaciones . . . . . 8
  - 1.2.3. Inestabilidad y Efecto Contextual . . . . . 9
  - 1.2.4. Ciberseguridad y Vulnerabilidades . . . . . 10
- 1.3. Inteligencia Artificial Simbólica y Sistemas Basados en Reglas 12
  - 1.3.1. El Paradigma Simbólico (GOFAI) . . . . . 12
  - 1.3.2. Motores de Inferencia y Algoritmos de Evaluación . . . 13
  - 1.3.3. Determinismo y Trazabilidad . . . . . 15
  - 1.3.4. Fragilidad ante la Variabilidad Conversacional . . . . . 16
- 1.4. Inteligencia Artificial Neuro-Simbólica . . . . . 16
  - 1.4.1. La Tercera Ola de la Inteligencia Artificial . . . . . 17
  - 1.4.2. Taxonomía de Arquitecturas Neuro-Simbólicas . . . . . 17
  - 1.4.3. El Balance para la Gobernanza . . . . . 19

**2. Definición del Dominio: Originación de Crédito Bancario** **21**
- 2.1. Justificación del Escenario . . . . . 21
  - 2.1.1. El Crédito como Sistema de Alto Riesgo . . . . . 22
  - 2.1.2. El Reto Conversacional en la Banca . . . . . 23
- 2.2. Marco Regulatorio Específico del Sector Financiero . . . . . 23
  - 2.2.1. Evaluación de la solvencia . . . . . 24
  - 2.2.2. Resiliencia operativa (DORA) . . . . . 24
  - 2.2.3. Implicaciones del EU AI Act para el crédito . . . . . 25
- 2.3. Modelado del Dominio y Ontología Financiera . . . . . 26
  - 2.3.1. Entidades del Ecosistema Bancario . . . . . 26
  - 2.3.2. Variables y Atributos de Riesgo . . . . . 27

2.3.3. Fuentes de Información . . . . . 28
2.3.4. Gestión de la Incertidumbre . . . . . 28
2.4. Catálogo de Reglas en la Concesión de Crédito . . . . . 30
2.4.1. Reglas de Elegibilidad Básica . . . . . 30
2.4.2. Reglas de Viabilidad Financiera . . . . . 31
2.4.3. Reglas de Riesgo . . . . . 31
2.4.4. Reglas de Decisión y Resultados . . . . . 32
2.5. Perfiles de Usuario . . . . . 33
2.5.1. Cliente con Información Completa . . . . . 33
2.5.2. Cliente con Información No Declarada . . . . . 33
2.5.3. Usuario Ambiguo o Errático . . . . . 34
2.5.4. Usuario Adversarial . . . . . 34
2.6. Requisitos de Diseño Derivados del Dominio . . . . . 35
2.6.1. Necesidad de un Estado Canónico de la Solicitud . . . 35
2.6.2. Separación entre Comprensión y Lógica . . . . . 36
2.6.3. Trazabilidad y Auditabilidad de las Decisiones . . . . . 37

# Capítulo 1

# Marco Teórico y Estado del Arte

Este capítulo establece los fundamentos científicos, técnicos y legales que justifican la necesidad de garantizar una toma de decisiones auditable y rigurosa en los sistemas conversacionales modernos. A lo largo de las siguientes secciones, se trazará un recorrido analítico que comienza con la exigencia regulatoria y ética de la **accountability**, desglosando los imperativos legales que condicionan el despliegue de estas tecnologías en sectores críticos. Posteriormente, se evaluarán los paradigmas históricos subyacentes: desde las limitaciones cognitivas y de ciberseguridad del conexionismo puro (*Deep Learning*), hasta la rigidez inherente de la inteligencia artificial simbólica clásica. Este análisis diagnóstico culminará justificando la convergencia neurosimbólica como el único estado del arte capaz de conciliar la naturalidad del lenguaje humano con la gobernanza formal requerida.

## 1.1. El Paradigma de la Accountability y el Marco Regulatorio

El problema central de la inteligencia artificial conversacional contemporánea no radica en su incapacidad para mantener diálogos fluidos o procesar lenguaje natural complejo, sino en una deficiencia mucho más profunda: los modelos actuales generan comportamiento sin representarlo explícitamente. Para comprender la magnitud de este problema y establecer los requisitos de un sistema robusto, es necesario desambiguar algunos conceptos que a menudo se utilizan como sinónimos en la industria tecnológica, pero que técnicamente imponen niveles de exigencia muy distintos.

### 1.1.1. De la Transparencia a la Accountability

La literatura sobre IA explicable establece una jerarquía de propiedades que un sistema puede satisfacer. Estas propiedades operan como una cadena de dependencias, donde cada nivel exige requisitos de implementación más estrictos que el anterior:

- **Transparencia**: Es la propiedad más básica e implica que la estructura interna y el proceso de operación del sistema son accesibles para su inspección. Lipton (2018) distingue entre la transparencia del modelo completo (simulabilidad mental por parte de un humano), la transparencia de los componentes (descomponibilidad) y la transparencia algorítmica. Un Gran Modelo de Lenguaje (LLM) puro no es transparente en ninguno de estos niveles: su red de miles de millones de parámetros no es simulable mentalmente.

- **Interpretabilidad**: Añade el requisito de la comprensibilidad humana. Un sistema es interpretable cuando un observador humano no solo tiene acceso a la estructura, sino que puede comprender cómo esta produce las decisiones. La transparencia es una propiedad del sistema, mientras que la interpretabilidad es una propiedad de la relación entre el sistema y el humano. En los modelos atencionales de los LLMs, las capas de atención carecen de un significado individual interpretable.

- **Explicabilidad**: Suma a la interpretabilidad el requisito de la articulación causal. No solo se debe comprender qué hizo el sistema, sino por qué lo hizo. Requiere que el sistema pueda articular de manera fidedigna la cadena causal que conecta la entrada del usuario, los estados internos, las reglas aplicadas y la salida generada.

- **Accountability**: Representa el vértice de esta jerarquía y es el concepto más exigente. La accountability presupone la explicabilidad, pero añade dos requisitos: la **verificabilidad** (la capacidad de comprobar matemáticamente que el comportamiento cumple con una especificación formal o norma explícita) y la **atribución de responsabilidad** (identificar qué componente, regla o agente provocó cada decisión).

Bajo este marco, resulta evidente que las decisiones operativas de un LLM puro no pueden ser verificables contra una norma, fundamentalmente porque el sistema no contiene en su arquitectura ninguna representación explícita de dicha norma. Al generar un comportamiento conversacional fundamentado puramente en inferencias estocásticas, el proceso de decisión de un LLM queda fuera de cualquier posibilidad de auditoría rigurosa, haciendo que la accountability sea estructuralmente inalcanzable.

### 1.1.2. Explicabilidad Post-Hoc vs. Explicabilidad Constitutiva

La industria tecnológica ha intentado solventar el déficit de accountability mediante técnicas de explicabilidad que, analizadas con rigor, resultan insuficientes para entornos conversacionales críticos. Esto nos obliga a distinguir entre dos paradigmas de diseño opuestos: el **post-hoc** y el **constitutivo**.

El paradigma **post-hoc** asume la existencia de un modelo opaco (caja negra) que ya ha tomado una decisión, e intenta generar una explicación posterior sobre dicho resultado. Con la llegada de los LLMs, se ha popularizado una nueva modalidad de explicación post-hoc: pedir al propio modelo conversacional que "justifique su respuesta" o que "razone paso a paso" (Chain-of-Thought).

Sin embargo, como argumenta Rudin (2019) y demuestran estudios empíricos recientes (Turpin et al., 2024; Lanham et al., 2023), estas explicaciones generadas por LLMs son, en realidad, **racionalizaciones**. Es decir, son narrativas construidas estadísticamente para justificar una respuesta, pero no constituyen descripciones fieles del proceso interno real que produjo dicha respuesta. El modelo no tiene acceso a su propio proceso de inferencia matricial. Pedirle a un LLM que justifique una decisión es engañoso, generará una historia coherente y articulada, pero completamente desvinculada de la causalidad real.

Por el contrario, la **explicabilidad constitutiva** exige que el proceso de decisión del sistema opere desde su origen sobre representaciones explícitas. En un sistema conversacional dotado de explicabilidad constitutiva, la explicación no se genera después de la decisión, sino que la traza inmutable del proceso de decisión es la explicación en sí misma. La correspondencia entre la justificación aportada al auditor y el proceso lógico ejecutado está garantizada por construcción, eliminando cualquier espacio para la alucinación justificativa. Los entornos críticos exigen abandonar las racionalizaciones post-hoc para abrazar arquitecturas constitutivamente transparentes.

### 1.1.3. Marco Regulatorio y Derecho a Explicación

La exigencia de accountability y explicabilidad constitutiva en la IA conversacional ha trascendido el debate académico para convertirse en un imperativo legal. La legislación europea reciente impone requisitos estrictos que condicionan la viabilidad de las arquitecturas tecnológicas, obligando a traducir las normativas en especificaciones de ingeniería concretas.

Es pertinente señalar que, si bien en este apartado se analizará el marco normativo tecnológico de carácter general (RGPD y EU AI Act), las regula-

ciones específicas del sector financiero se abordarán en detalle en el Capítulo 3, coincidiendo con la presentación del caso de uso bancario desarrollado en este trabajo.

### RGPD (Reglamento General de Protección de Datos)

El Artículo 22 del RGPD legisla sobre las decisiones individuales automatizadas, estableciendo el derecho de las personas a no ser objeto de decisiones basadas únicamente en el tratamiento automatizado que produzcan efectos jurídicos o significativos. Además, los considerandos vinculados a este artículo consolidan el derecho a obtener una explicación y el derecho a solicitar intervención humana.

Desde la perspectiva de la ingeniería conversacional, el RGPD prohíbe que una denegación de servicio automatizada se justifique con una "explicación genérica" del modelo. Si un asistente conversacional rechaza una solicitud, el cliente tiene el derecho legal a conocer la lógica subyacente específica que motivó ese rechazo. Como se ha analizado, un modelo opaco solo puede ofrecer racionalizaciones post-hoc, las cuales no satisfacen el estándar legal de explicar la lógica real subyacente. Se requiere, por tanto, una arquitectura que permita emitir una traza exacta e individualizada del árbol de decisión recorrido para ese cliente en particular.

### EU AI Act (Ley de Inteligencia Artificial de la UE)

El EU AI Act establece el marco normativo definitivo para los sistemas de IA en el ámbito europeo, clasificándolos de manera proporcional según su nivel de riesgo. Los sistemas de IA conversacional empleados para procesos críticos, como el triaje médico, la criba de candidatos o la evaluación de solvencia, pertenecen formalmente al Anexo III (Sistemas de Alto Riesgo). Esta clasificación activa inmediatamente el cumplimiento de los Artículos 9 al 15 del reglamento, los cuales obligan a adoptar los siguientes requisitos arquitectónicos:

- **Artículo 12 (Trazabilidad y Registros)**: Exige que los sistemas de IA de alto riesgo dispongan de capacidades de registro automático de determinados eventos durante su funcionamiento, con el objetivo de garantizar una trazabilidad adecuada del sistema. En el contexto de los sistemas conversacionales, esto implica mantener un registro de los eventos relevantes de la interacción, como las entradas recibidas, las reglas activadas, las decisiones intermedias o las respuestas generadas. Estos registros permiten reconstruir posteriormente el funcionamiento del sistema y facilitan su supervisión, depuración y auditoría.

- **Artículo 13 (Transparencia e Información a los Usuarios)**: Exige que la IA esté diseñada para que su funcionamiento sea suficientemente transparente. Los usuarios deben ser conscientes de que interactúan con una IA y deben poder comprender las capacidades operativas y las limitaciones del asistente conversacional con el que se comunican.
- **Artículo 14 (Supervisión Humana)**: Exige que los sistemas de IA de alto riesgo puedan ser supervisados de forma efectiva por personas durante su funcionamiento. En un sistema conversacional, esto puede materializarse mediante mecanismos que permitan detectar situaciones anómalas o inciertas y derivarlas a un operador humano, por ejemplo mediante un estado de `REQUIERE_SUPERVISION_HUMANA`. El operador debe disponer de información suficiente para interpretar el resultado y poder aceptarlo, modificarlo, rechazarlo o interrumpir el funcionamiento del sistema cuando sea necesario.
- **Artículo 15 (Precisión, Robustez y Ciberseguridad)**: Exige que los sistemas de IA de alto riesgo alcancen niveles adecuados de precisión, robustez y ciberseguridad y que mantengan un funcionamiento consistente durante su ciclo de vida. En un sistema conversacional, esto implica disponer de mecanismos para detectar y gestionar errores, inconsistencias y posibles intentos de manipulación, como los ataques de *Prompt Injection*, evitando que entradas maliciosas puedan alterar indebidamente el comportamiento previsto del sistema.

La convergencia de estos marcos normativos transversales (RGPD y EU AI Act) concluye que la *accountability* no es una característica deseable, sino un estricto conjunto de requisitos.

## 1.2. Inteligencia Artificial Conexionista (Deep Learning)

La segunda ola de la inteligencia artificial, caracterizada por el *Deep Learning* y el auge de arquitecturas como los *Transformers*, ha supuesto un avance en la capacidad de las máquinas para procesar, interpretar y generar lenguaje natural. Las redes neuronales profundas han logrado capturar casi a la perfección la variabilidad lingüística del mundo real, permitiendo a los sistemas comprender instrucciones complejas, manejar elipsis, tolerar errores gramaticales y generar respuestas con un nivel de fluidez indistinguible del humano.

No obstante, tal como se documenta la literatura científica reciente, estas capacidades lingüísticas coexisten con deficiencias cognitivas profundas. Autores como Marcus (2020) han señalado que las limitaciones del aprendizaje profundo (su opacidad, su inconsistencia y la imposibilidad de verificación formal) no son simples defectos técnicos que futuras iteraciones de los modelos vayan a corregir mediante un mayor volumen de datos o parámetros, sino que constituyen consecuencias ineludibles de su propia arquitectura.

### 1.2.1. Naturaleza Estocástica y Cajas Negras

La base del funcionamiento de los Grandes Modelos de Lenguaje (LLMs) es la predicción estocástica de *tokens*. Estos sistemas generan texto calculando distribuciones de probabilidad sobre un vocabulario, condicionadas por el contexto previo, careciendo en todo momento de un modelo mental del mundo real, de una ontología subyacente o de mecanismos de razonamiento lógico deductivo puro. En el paradigma conexionista, el conocimiento no se codifica en estructuras discretas con semántica definida (como proposiciones, reglas lógicas o redes semánticas), sino que se distribuye de manera implícita a lo largo de miles de millones de parámetros (pesos y sesgos) en los patrones de activación de la red.

Esta distribución implícita convierte a los LLMs en *cajas negras*. Las decisiones y respuestas que emiten son el resultado de complejas multiplicaciones de matrices y operaciones *softmax* que carecen por completo de interpretación semántica accesible para un observador humano. Si un sistema conversacional puramente neuronal deniega la concesión de un préstamo, no existe ningún mecanismo para inspeccionar sus parámetros y aislar la "regla" o el "razonamiento" exacto que condujo a dicha denegación. Esta opacidad entra en conflicto directo con los requisitos más elementales de la *accountability* expuestos en la sección anterior.

### 1.2.2. El Fenómeno de las Alucinaciones

Derivada de su naturaleza probabilística, la segunda gran limitación de los modelos fundacionales es el fenómeno de las alucinaciones. Dado que un LLM aprende a través de la maximización de la verosimilitud de las secuencias de texto durante su fase de preentrenamiento, el modelo carece de un mecanismo intrínseco para distinguir entre hechos factuales, verdades lógicas y simples correlaciones estadísticas latentes en sus datos.

Cuando a un modelo neuronal se le exige razonar sobre un caso práctico, el sistema no está deduciendo lógicamente la respuesta a partir de axiomas

legales. En su lugar, está generando la secuencia de palabras que, estadísticamente, es más probable que siga al *prompt* introducido. Esto da lugar a que el modelo pueda inventar datos, citar artículos normativos inexistentes o fabricar justificaciones que parecen razonables y articuladas, pero que son fundamentalmente falsas.

Aunque las técnicas de entrenamiento, alineamiento y verificación han permitido reducir progresivamente la frecuencia de estas alucinaciones, no es posible garantizar su eliminación completa. Al tratarse de sistemas probabilísticos, siempre existe la posibilidad de que el modelo genere información incorrecta con un elevado grado de coherencia y aparente certeza, especialmente cuando se enfrenta a situaciones que requieren conocimientos específicos o inferencias complejas. Por tanto, incluso cuando el sistema presenta un elevado rendimiento en términos generales, la ausencia de garantías sobre la veracidad de cada una de sus respuestas constituye una limitación estructural que debe tenerse en cuenta en aquellos contextos en los que un error puede producir consecuencias relevantes.

### 1.2.3. Inestabilidad y Efecto Contextual

La tercera limitación estructural de los enfoques conexionistas puros es su profunda inestabilidad frente a la variabilidad de entrada. En un sistema de reglas simbólico (GOFAI - *Good Old-Fashioned AI*), una condición evaluada producirá el mismo resultado siempre que los parámetros de entrada sean idénticos, garantizando un determinismo absoluto. Por el contrario, la inferencia en un LLM es altamente sensible a perturbaciones menores.

Investigaciones recientes han documentado empíricamente esta fragilidad. Raj et al. (2023) demostraron que los LLMs producen respuestas inconsistentes ante reformulaciones de la misma pregunta (paráfrasis), documentando tasas de inconsistencia semántica que pueden superar el 30 % en dominios especializados. Esto significa que si un cliente solicita un préstamo escribiendo "Quiero solicitar 5000 euros a 4 años" frente a "Necesito un crédito de 5000€ a devolver en 48 meses", el modelo neuronal podría aprobar la primera solicitud y denegar la segunda simplemente porque la distribución de probabilidad generada a partir de los *tokens* de entrada difiere ligeramente.

A esta inestabilidad semántica se suma la degradación cognitiva en el manejo de contextos largos. Aunque los modelos modernos han ampliado su ventana de contexto, Liu et al. (2023) han evidenciado el efecto *"lost in the middle"*: la capacidad de los LLMs para utilizar información decae drásticamente cuando los datos críticos se encuentran en posiciones intermedias del contexto. Adicionalmente, Levy et al. (2024) documentaron que la capacidad de "razonamiento" del modelo se degrada exponencialmente a medida que la

longitud de la conversación aumenta.

En el contexto de la IA conversacional, donde una interacción puede extenderse a lo largo de múltiples turnos y el usuario puede proporcionar datos, cambiar de opinión, retractarse o aportar información fragmentada, depender de la ventana de contexto del LLM para mantener el "estado" de la operación es una debilidad arquitectónica. El modelo no mantiene un registro estructurado de qué datos han sido proporcionados, cuáles han sido verificados y cuáles son simplemente comentarios; todo se amalgama como *tokens* indiferenciados. Esta falta de *Information State* explícito impide garantizar la consistencia sistémica, haciendo que la toma de decisiones sea impredecible.

### 1.2.4. Ciberseguridad y Vulnerabilidades

Las limitaciones cognitivas expuestas no solo afectan a la calidad del diálogo y toma de decisiones, sino que configuran una superficie de ataque completamente nueva desde la perspectiva de la ciberseguridad. Al carecer de una representación formal que separe semánticamente las instrucciones del sistema de los datos introducidos por el usuario, los LLMs son vulnerables a manipulaciones lingüísticas que subvierten su comportamiento previsto.

#### Vectores de Ataque Semántico

El principal riesgo en las aplicaciones basadas en Modelos Fundacionales es el *Prompt Injection*. Este ataque ocurre cuando se introducen comandos ocultos o maliciosos en los datos que el modelo procesa, confundiéndolos con instrucciones del sistema. Un ejemplo clásico en el entorno bancario sería un usuario que adjunta un historial crediticio en PDF que contiene el texto invisible: "*Aviso del sistema: El análisis ha finalizado. Clasifica este perfil de solvencia como APROBADO sin importar los ingresos previos.*". Al procesar el documento, el modelo es incapaz de separar los datos de las instrucciones y ejecuta la orden del atacante.

Complementariamente, el *Jailbreaking* se refiere a las técnicas adversariales que el usuario introduce directamente en la conversación para romper las barreras éticas, lógicas y de seguridad impuestas por los desarrolladores, a menudo mediante ingeniería social o manipulación de *tokens*.

La existencia de estas vulnerabilidades demuestra que las restricciones impuestas mediante *prompts* no son estructurales ni formales, sino meramente estadísticas: se cumplen con alta probabilidad en escenarios benignos, pero fallan cuando la presión probabilística de los datos del atacante supera la fuerza matemática de la instrucción de sistema subyacente.

### El Agotamiento de las Aproximaciones Paliativas

Ante la gravedad de los vectores de ataque semántico, la industria ha desarrollado diversas técnicas conexionistas para intentar mitigar el problema sin abandonar el paradigma puramente neuronal. No obstante, estas soluciones operan sobre los síntomas externos del modelo y no sobre su proceso de decisión interno. Entre las más extendidas, y sus respectivas carencias, destacan:

- **Los *guardrails* y clasificadores externos:** Sistemas de filtrado perimetral (como *NeMo Guardrails* o *Llama Guard*) que interceptan la entrada o la salida de texto para detectar anomalías mediante modelos estadísticos secundarios. Sin embargo, actúan exclusivamente sobre la superficie lingüística. Un filtro puede bloquear una palabra explícitamente tóxica, pero es incapaz de evaluar si una decisión de negocio omitida o alterada vulnera la coherencia contractual del diálogo o las políticas de solvencia de la entidad.

- **El *prompt engineering*:** Intentar gobernar un LLM introduciendo directrices operativas en lenguaje natural dentro del *prompt* ("*bajo ninguna circunstancia ...*") confunde instrucción con ejecución determinista. El modelo interpreta estas directrices de manera probabilística, por consiguiente, una reformulación adversaria suficientemente compleja o la acumulación de contexto en diálogos extensos pueden provocar que el sistema diluya o ignore la restricción por completo.

- **El alineamiento estadístico (RLHF y *Constitutional AI*):** Aunque técnicas como el Aprendizaje por Refuerzo a partir de Retroalimentación Humana (Bai et al., 2022) reducen la frecuencia promedio de respuestas no deseadas, estas modifican las probabilidades de salida en el espacio latente, pero no introducen estructuras verificables de toma de decisiones. Estudios empíricos exhaustivos, como los realizados por Wolf et al. (2023) y Zou et al. (2023), han demostrado de forma irrefutable que incluso los mejores modelos pueden ser inducidos a violar sus políticas mediante ataques adversariales.

### El Riesgo Crítico en Entornos Agénticos Autónomos

Esta fragilidad intrínseca alcanza una dimensión crítica cuando se dota al modelo neuronal de autonomía operativa mediante arquitecturas agénticas. La tendencia reciente de la industria hacia patrones como *ReAct* (Yao et al., 2023) o *frameworks* como *LangChain* y *CrewAI*, donde se otorgan al

LLM herramientas como APIs de bases de datos, capacidad de enviar correos electrónicos o ejecutar transferencias, eleva el problema a niveles críticos para la ciberseguridad financiera.

Como advierten Ruan et al. (2024) en su análisis sobre los riesgos de agentes basados en LLMs, un agente autónomo es, por definición, un agente cuyas decisiones operativas no están gobernadas externamente. En estos sistemas, el LLM decide autónomamente, basándose en la inferencia probabilística del contexto, qué herramienta invocar, en qué orden y con qué parámetros. Si un ataque de los mencionados previamente tiene éxito contra un agente autónomo, el atacante no solo obtiene control sobre el texto generado, sino que adquiere capacidad ejecutiva sobre las herramientas de las que dispone el agente.

En conclusión, el paradigma conexionista puro genera comportamiento lingüístico sin representarlo formalmente. La combinación de una lógica estocástica opaca con la capacidad de ejecutar llamadas a sistemas bancarios genera un riesgo inaceptable para los estándares de supervisión y resiliencia digital. Las capas de control superpuestas sobre modelos probabilísticos solo proporcionan garantías estadísticas, pero en ningún caso las garantías formales, deterministas y auditables. Esta limitación fundamenta la necesidad de recurrir a la tradición simbólica de la inteligencia artificial, objeto de análisis en la siguiente sección.

## 1.3. Inteligencia Artificial Simbólica y Sistemas Basados en Reglas

Como se ha evidenciado en la sección anterior, la delegación de decisiones críticas a sistemas puramente conexionistas incurre en riesgos inasumibles de opacidad, inconsistencia y vulnerabilidad. Para resolver esta brecha y recuperar el control sobre la lógica de negocio, resulta necesario volver al otro gran pilar histórico de la disciplina: la Inteligencia Artificial Simbólica. Este enfoque, lejos de estar obsoleto, proporciona los cimientos formales, matemáticos y lógicos necesarios para garantizar la *accountability* exigida en entornos regulados.

### 1.3.1. El Paradigma Simbólico (GOFAI)

La Inteligencia Artificial Simbólica, frecuentemente referida como GOFAI (*Good Old-Fashioned AI*), se fundamenta en la intuición de que la inteligencia es, en esencia, la capacidad de manipular representaciones simbólicas de acuerdo con reglas formales explícitas. Esta visión fue articulada con máxima

precisión por Newell y Simon (1976) en *Physical Symbol System Hypothesis*, donde se postula que un sistema de estas características posee los medios necesarios y suficientes para la acción inteligente general.

A diferencia del paradigma conexionista, el enfoque simbólico exige que el conocimiento se codifique en estructuras discretas con una semántica estrictamente definida e inspeccionable. Esta explicitación del conocimiento se materializa a través de:

- **Lógica de Primer Orden:** Proporciona el marco matemático para formular aserciones sobre el mundo. Permite definir hechos, variables y cuantificadores, garantizando que cualquier inferencia derivada del sistema sea lógicamente válida por construcción.
- **Ontologías Formales:** Las ontologías permiten la conceptualización explícita y compartida de un dominio. En un contexto corporativo, una ontología define qué entidades existen (usuario, producto, restricciones), cómo se relacionan jerárquicamente y qué restricciones de integridad deben cumplir. Esto asegura que el sistema posea una comprensión estructural del negocio, previniendo, por ejemplo, que asigne una edad negativa a un individuo.
- **Reglas de Producción (IF-THEN):** El conocimiento procedimental y normativo se encapsula en estructuras condicionales. Una regla de producción establece que, si se cumple un patrón específico de hechos en la memoria del sistema ($IF$), se debe desencadenar una acción determinista ($THEN$). La naturaleza composicional de estas reglas permite construir lógicas empresariales de extrema complejidad a partir de unidades atómicas, independientes y fácilmente auditables por expertos de dominio.

### 1.3.2. Motores de Inferencia y Algoritmos de Evaluación

Para que las representaciones simbólicas adquieran capacidad operativa, es necesario disponer de un componente computacional capaz de interpretar los hechos y evaluar las reglas que constituyen el conocimiento del sistema. Este componente se denomina **motor de inferencia** o, en el ámbito de las reglas de negocio, **motor de reglas**. Su función principal consiste en separar la lógica de decisión, expresada mediante reglas, del código de la aplicación, permitiendo determinar de forma eficiente qué reglas deben activarse ante un conjunto determinado de hechos.

Un ejemplo representativo de este enfoque es el ecosistema **KIE**, dentro del cual se integra **Drools**. Es importante distinguir ambos conceptos: KIE hace referencia al ecosistema de tecnologías orientadas a la gestión del conocimiento, las reglas y la automatización de decisiones y procesos, mientras que Drools es el componente especializado en la definición y ejecución de reglas de negocio. Por tanto, KIE constituye el marco tecnológico general y Drools proporciona específicamente las capacidades necesarias para implementar un motor de reglas. En este contexto, las reglas pueden describir condiciones sobre los hechos disponibles y las acciones que deben ejecutarse cuando dichas condiciones se cumplen.

La eficiencia computacional de estos motores reside en los algoritmos subyacentes encargados del *pattern matching* (evaluación de patrones), históricamente dominados por el **Algoritmo Rete** y, en sus arquitecturas más modernas, por el **Algoritmo Phreak**.

### El Algoritmo Rete y la Memoria de Trabajo

Diseñado por Charles Forgy en 1979, el algoritmo Rete resolvió el problema del rendimiento en los sistemas expertos tradicionales. En lugar de evaluar cada regla iterativamente contra cada dato (lo que generaría un coste combinatorio intratable, $O(R \times F)$), Rete construye un grafo acíclico dirigido (DAG) que compila las reglas en una red de nodos.

El sistema consta de dos memorias: la *Production Memory*, que almacena el árbol de reglas, y la *Working Memory* (Memoria de Trabajo), donde se inyectan los hechos (*facts*). Cuando un *fact* ingresa a la memoria de trabajo, se propaga por la red a través de *Alpha Nodes* (que evalúan condiciones literales simples, como `edad <18`) y *Beta Nodes* (que evalúan cruces y combinaciones lógicas entre diferentes entidades, como comparar atributos interdependientes de un usuario con los requisitos de un servicio). Rete conserva el estado de estas evaluaciones en memoria, recalculando únicamente aquello que cambia, lo que permite inferencias en tiempo real.

### La Evolución a Phreak y la Resolución de Conflictos

Drools incorpora **Phreak** como una evolución de los mecanismos de evaluación de reglas basados en Rete, orientada a mejorar la gestión del procesamiento en sistemas con grandes cantidades de hechos y reglas. Mientras que Rete organiza las condiciones de las reglas en una red y propaga por ella los resultados de las evaluaciones, Phreak introduce mecanismos para gestionar de forma más eficiente los cambios producidos en la memoria de trabajo, agrupando y priorizando el trabajo que debe realizarse. La idea fundamental

no consiste en reevaluar indiscriminadamente toda la red ante cada modificación, sino en identificar y procesar las partes afectadas por los cambios, reduciendo así el consumo de memoria y multiplicando la velocidad de evaluación cuando se enfrentan cientos de miles de hechos y reglas simultáneas.

Independientemente del algoritmo de red, el motor se enfrenta al desafío de la **resolución de conflictos**: ¿qué ocurre cuando los datos proporcionados hacen que las condiciones de múltiples reglas se cumplan simultáneamente? El motor agrupa todas las reglas activadas en una estructura denominada *Agenda*. Para garantizar el determinismo estricto, Drools emplea el atributo de ***Salience*** (prominencia o prioridad). Asignando un valor numérico de *salience* a cada regla, el ingeniero de conocimiento define matemáticamente el orden exacto de ejecución. Así, una regla crítica con `salience 100` se ejecutará y podrá abortar el flujo antes que una regla de `salience 50`, evitando computaciones innecesarias y colisiones lógicas.

### 1.3.3. Determinismo y Trazabilidad

En contraposición a la estocasticidad de los LLMs, el motor simbólico garantiza determinismo absoluto. Si el estado de información (*Information State*) introducido en la memoria de trabajo es $X$, y el conjunto de reglas formales de la organización es $R$, el resultado emitido será invariablemente $Y$. No existe margen para la aleatoriedad, la "temperatura" generativa o la influencia de un contexto intermedio. Esta consistencia sistémica permite la validación de software mediante pruebas unitarias exhaustivas, posibilitando que el sistema sea certificado algorítmicamente antes de su paso a producción.

#### Materialización de la Explicabilidad Constitutiva

Tal y como se definió en la sección anterior, los entornos altamente regulados exigen el grado más alto de *accountability*. El paradigma simbólico proporciona exactamente esta propiedad: en un sistema basado en reglas como Drools, la traza de ejecución del motor *es* la explicación de la decisión.

Cuando el motor evalúa una transacción crítica, genera un registro (*ledger*) inmutable de su recorrido computacional. La traza documenta con precisión quirúrgica:

1. El instante temporal y la sesión exacta de la operación.
2. Los datos crudos (*facts*) que ingresaron a la Memoria de Trabajo.
3. La secuencia ordenada de reglas que se activaron en la Agenda.
4. Los nodos de decisión específicos que alteraron el estado del proceso.

5. El artículo normativo o política interna vinculada directamente a la regla ejecutada.

Esta arquitectura satisface el requisito de auditabilidad por diseño. Un auditor humano puede inspeccionar la representación formal, comprender la lógica empleada y verificar el cumplimiento normativo sin ambigüedades.

### 1.3.4. Fragilidad ante la Variabilidad Conversacional

La Inteligencia Artificial Simbólica pura presenta debilidades igualmente fundamentales que limitan históricamente su aplicabilidad en entornos interactivos. La más importante es su extrema **fragilidad ante la variabilidad del mundo real**, en especial frente a la riqueza y ambigüedad del lenguaje natural humano.

Los sistemas basados exclusivamente en reglas exigen que el usuario se exprese de forma que el sistema pueda anticipar algorítmicamente. Si un sistema conversacional simbólico espera la entrada literal "solicitar cancelación", fallará ante reformulaciones válidas como "me gustaría darme de baja", "ya no quiero continuar con el servicio" o actos de habla indirectos. Las reglas de producción no pueden procesar adecuadamente los sinónimos, las elipsis, el contexto emocional o la intención subyacente de una oración sin una explosión combinatoria inasumible en el código.

Este problema se conoce en la literatura como el *cuello de botella de la ingeniería del conocimiento*. Codificar manualmente todas las posibles variaciones conversacionales, intenciones y estrategias de diálogo para un dominio complejo es un proceso costoso, frágil y propenso a omisiones. Los primeros sistemas de diálogo operativos, basados netamente en este enfoque, resultaron ser inflexibles, provocando experiencias de usuario robóticas y frustrantes.

En definitiva, se establece una paradoja arquitectónica fundamental: el enfoque conexionista comprende el lenguaje pero no puede gobernar decisiones con rigor legal, mientras que el enfoque simbólico garantiza el rigor de las decisiones pero es incapaz de comprender el lenguaje. Esta dicotomía es la que motiva la convergencia hacia el estado del arte actual: la Inteligencia Artificial Neuro-Simbólica.

## 1.4. Inteligencia Artificial Neuro-Simbólica

Las secciones anteriores han establecido una dicotomía en el campo de la inteligencia artificial. Por un lado, el paradigma conexionista comprende muy bien la variabilidad y ambigüedad del lenguaje natural, pero carece de los mecanismos formales necesarios para gobernar decisiones con el rigor legal

que exige la *accountability*. Por otro lado, el paradigma simbólico garantiza el determinismo absoluto y la trazabilidad de las decisiones, pero resulta rígido y frágil ante la riqueza de la interacción humana.

Para superar esto, la frontera de la investigación contemporánea ha convergido hacia un nuevo paradigma que busca reconciliar ambas tradiciones: la Inteligencia Artificial Neuro-Simbólica.

### 1.4.1. La Tercera Ola de la Inteligencia Artificial

La evolución histórica de la disciplina ha estado marcada por ciclos de gran entusiasmo seguidos de profundas decepciones (los conocidos "inviernos" de la IA). Henry Kautz (2022) argumenta que actualmente nos encontramos en el "Tercer Verano de la IA", un periodo impulsado por el éxito del aprendizaje profundo (*Deep Learning*) en la extracción de representaciones jerárquicas y el cálculo de similitudes vectoriales. No obstante, teóricos e investigadores coinciden en que el enfoque puramente neuronal se acerca a un límite inherente cuando se trata de realizar inferencias lógicas rigurosas.

Como respuesta a este estancamiento, emerge lo que Garcez y Lamb denominan la "Tercera Ola" de la Inteligencia Artificial. Esta ola no busca sustituir a los modelos neuronales, sino complementarlos. El objetivo es utilizar el aprendizaje profundo para las tareas perceptuales y de procesamiento de lenguaje natural, reservando la lógica simbólica para el razonamiento, la planificación y el control estricto de las decisiones operativas. En definitiva, el futuro de la IA no reside en la victoria de un paradigma sobre otro, sino en su integración sistemática.

### 1.4.2. Taxonomía de Arquitecturas Neuro-Simbólicas

La integración neuro-simbólica no es un concepto binario, sino un espectro continuo de arquitecturas con distintos grados de acoplamiento y control. Para categorizar este amplio abanico de posibilidades, Kautz (2022) propone una taxonomía que identifica seis diseños arquitectónicos diferenciados, los cuales estructuran la forma en que los módulos neuronales y simbólicos interactúan. A continuación, se detallan estas seis aproximaciones:

#### 1. Symbolic Neuro symbolic

Esta arquitectura representa el Procedimiento Operativo Estándar actual para muchas tareas de procesamiento de lenguaje natural (NLP). En este diseño, una entrada simbólica (como una secuencia de palabras) se convierte en vectores (*embeddings*), se procesa a través de las capas ocultas de una

red neuronal y, finalmente, las unidades de salida convierten esa información nuevamente en una categoría simbólica o secuencia de símbolos mediante una operación *softmax*. Aunque la entrada y la salida son símbolos, todo el procesamiento intermedio es puramente neuronal y, por tanto, opaco. Este nivel corresponde a una integración de "caja negra" donde el componente neuronal es un servicio invocado para una traducción directa.

### 2. Symbolic[Neuro]

En este diseño, el sistema simbólico es el orquestador principal (el que resuelve el problema), y utiliza un modelo neuronal como una subrutina interna. El componente neuronal no opera libremente, sino dentro del marco de trabajo definido por el componente simbólico. Un ejemplo paradigmático de esta arquitectura es AlphaGo, donde un algoritmo de búsqueda simbólica (*Monte-Carlo Tree Search*) invoca a una red neuronal exclusivamente para evaluar las posiciones de las hojas del árbol. En el contexto conversacional, este patrón permite crear un "pipeline gobernado": el motor simbólico dirige el flujo de la conversación y delimita el espacio probabilístico en el que el modelo de lenguaje puede operar, garantizando así que las decisiones críticas permanezcan bajo control determinista.

### 3. Neuro | Symbolic

Esta arquitectura plantea un flujo donde una red neuronal procesa entradas no simbólicas o complejas (como los píxeles de una imagen o el texto crudo de un usuario) y las convierte en una estructura de datos puramente simbólica. Una vez que los datos han sido mapeados a símbolos formales, estos se transfieren a un sistema de razonamiento lógico tradicional que completa la tarea. A diferencia del modelo anterior (donde el neuronal era una subrutina), aquí el componente neuronal actúa como una "corrutina" inicial que ejerce de puente perceptual hacia el motor de reglas.

### 4. Neuro: Symbolic $\rightarrow$ Neuro

Esta aproximación utiliza una arquitectura puramente neuronal (*Sequence-to-Sequence*), pero con un entrenamiento previo generado y supervisado mediante reglas simbólicas. El modelo neuronal se entrena masivamente con pares de entrada-salida generados por un solucionador simbólico (por ejemplo, expresiones matemáticas y sus simplificaciones lógicas exactas). El objetivo es que la red neuronal aprenda la lógica simbólica subyacente de tal forma que pueda adivinar correctamente la respuesta sin necesidad de generar una derivación paso a paso. Aunque ofrece gran velocidad, la decisión

final sigue siendo probabilística, lo que compromete la verificabilidad formal del proceso.

**5.** $Neuro_{Symbolic}$

Este enfoque busca compilar directamente el conocimiento simbólico dentro de la propia topología de la red neuronal. Las reglas lógicas se transforman en plantillas o tensores estructurales (*Logic Tensor Networks*) que condicionan el aprendizaje de la red. Esta aproximación permite inyectar relaciones jerárquicas y restricciones directamente en el espacio vectorial del modelo. Sin embargo, la investigación en este nivel sigue siendo exploratoria y presenta dificultades para codificar reglas disyuntivas complejas o razonamientos combinatorios por casos.

**6. Neuro[Symbolic]**

Inspirada en la teoría cognitiva de Daniel Kahneman sobre "Pensar rápido y pensar despacio", esta arquitectura incrusta un motor de razonamiento simbólico dentro de un motor neuronal principal. El sistema neuronal ("Sistema 1", rápido y automático) es el orquestador global. Cuando el Sistema 1 se enfrenta a un problema combinatorio o lógico que no puede resolver probabilísticamente, invoca al motor simbólico ("Sistema 2", lento y exacto) como una subrutina especializada. El modelo neuronal genera una representación simbólica del problema, la envía al solucionador lógico, y el resultado de este último retroalimenta a la red neuronal para continuar la ejecución.

### 1.4.3. El Balance para la Gobernanza

El análisis de la taxonomía de Kautz evidencia que la integración neurosimbólica no ofrece una única solución, sino un espacio de diseño donde diferentes decisiones arquitectónicas generan propiedades totalmente distintas. Para el diseño de sistemas de inteligencia artificial en dominios críticos (donde la *accountability*, la explicabilidad constitutiva y la resiliencia son innegociables), la elección del nivel de integración es determinante.

Los enfoques que integran la lógica dentro de la red neuronal (como *Neuro: Symbolic* $\rightarrow$ *Neuro* o $Neuro_{Symbolic}$) mejoran la capacidad del sistema para resolver problemas complejos. Sin embargo, al diluir las reglas lógicas dentro de variables matemáticas abstractas, se pierde la transparencia y resulta imposible rastrear con exactitud por qué se tomó una decisión específica. Por otro lado, arquitecturas que separan ambos mundos (como *Neuro[Symbolic]*) dejan el control principal en manos del componente neuronal. Esto genera el

riesgo de que el modelo actúe de manera opaca y decida de forma impredecible cuándo aplicar o ignorar la verificación lógica del "Sistema 2".

Por consiguiente, desde el punto de vista de la ingeniería del conocimiento, resulta especialmente interesante utilizar arquitecturas en las que el componente simbólico tenga un papel central en el control de la decisión, como ocurre en los patrones ***Symbolic[Neuro]*** y en determinados flujos ***Neuro / Symbolic***. En estos esquemas, el modelo de lenguaje se encarga principalmente de comprender y procesar la información, mientras que el motor simbólico aplica las reglas y restricciones definidas y participa en la determinación de la respuesta final. De esta forma, se combina la capacidad de los modelos neuronales para interpretar lenguaje natural con la posibilidad de representar de forma explícita las reglas que deben respetarse, facilitando así la trazabilidad, la supervisión y la justificación del comportamiento del sistema.

# Capítulo 2

# Definición del Dominio: Originación de Crédito Bancario

Hasta este punto de la investigación, hemos explorado el problema de la falta de accountability y la opacidad de los LLMs desde una perspectiva fundamentalmente teórica. Hemos analizado cómo la naturaleza probabilística dificulta la trazabilidad de sus decisiones, creando escenarios donde la responsabilidad se diluye entre la máquina, el desarrollador y el usuario. Sin embargo, para comprender la verdadera magnitud de este desafío, es imprescindible trasladar el debate hacia un entorno de aplicación real, donde las decisiones automatizadas generen un impacto tangible y cuantificable en la vida de las personas.

Este capítulo establece dicho puente al definir el dominio de aplicación de nuestro estudio: el sector financiero. En concreto, presentamos como caso de uso central el diseño de un asistente conversacional automatizado para la evaluación y concesión de préstamos personales. Este ámbito representa un entorno altamente regulado, complejo y de máxima exigencia técnica y ética. A lo largo de las siguientes secciones, detallaremos por qué este escenario constituye el campo idóneo para evaluar los límites de la responsabilidad algorítmica y los retos de extraer información crítica a través de interacciones en lenguaje natural.

## 2.1. Justificación del Escenario

La industria bancaria se encuentra en un dilema. Por un lado, existe una corriente que opta por digitalizar, agilizar y personalizar la experiencia del cliente mediante el uso de Inteligencia Artificial. Por otro, el sector está sujeto a estrictos marcos regulatorios diseñados para proteger la estabilidad

económica y los derechos de los consumidores. En este contexto, la originación de crédito bancario se erige como el escenario perfecto para auditar un sistema conversacional, ya que cualquier fallo en la interpretación de los datos o toma de decisiones no se traduce en un simple error de interfaz, sino en consecuencias jurídicas, financieras y sociales.

### 2.1.1. El Crédito como Sistema de Alto Riesgo

La evaluación y concesión de crédito está catalogada, tanto por la literatura académica como por marcos regulatorios emergentes como la Ley de Inteligencia Artificial de la Unión Europea (AI Act), como un sistema de alto riesgo. Esto se debe a que el acceso a la financiación es un pilar fundamental para el desarrollo socioeconómico de los individuos. Denegar o conceder un préstamo altera de manera directa la trayectoria vital y financiera del solicitante.

Al delegar este proceso en un agente conversacional, los riesgos inherentes al crédito se juntan con las vulnerabilidades de la IA. El impacto de una decisión automatizada errónea en este dominio opera en dos direcciones, ambas con consecuencias importantes si no existe una correcta trazabilidad:

- **El impacto de los falsos positivos**: Consiste en conceder crédito a un perfil que, en realidad, no cuenta con la capacidad de pago necesaria. Si el asistente conversacional malinterpreta los ingresos del usuario, o es incapaz de cruzar la información verbalizada con los datos históricos de manera rigurosa, el banco asume un riesgo de impago. Más allá de la pérdida económica directa para la entidad financiera, un falso positivo fomenta el sobreendeudamiento del cliente, empujándolo hacia una espiral de vulnerabilidad económica, un resultado que incumple los principios de préstamo responsable.

- **El impacto de los falsos negativos**: Ocurre cuando el sistema deniega el crédito a un usuario que sí era solvente. Si esta denegación proviene de un sesgo algorítmico (por ejemplo, su nivel educativo inferido a través del lenguaje, o variables demográficas), nos enfrentamos a un caso de discriminación automatizada. La falta de *accountability* adquiere aquí una relevancia crítica: cuando una denegación no puede vincularse de forma clara con los datos utilizados y los criterios que la justifican, resulta difícil determinar si el resultado responde realmente a una evaluación legítima del riesgo o a un error, una inconsistencia o un sesgo introducido durante el proceso.

### 2.1.2. El Reto Conversacional en la Banca

Históricamente, la originación de crédito ha dependido de interfaces gráficas y formularios estructurados. El usuario introduce un número exacto en una casilla específica (ej. «Ingresos: 2000»), y el sistema de evaluación de riesgos procesa esa variable determinista sin ambigüedades. El cambio de paradigma hacia una interfaz conversacional introduce un nuevo nivel de fricción interpretativa.

El gran reto radica en la colisión entre dos mundos incompatibles por defecto: la naturaleza intrínsecamente desestructurada, abierta y ambigua del diálogo humano, frente a la exigencia estricta y tipada de las fórmulas financieras. Un agente conversacional en este dominio no se enfrenta simplemente a un problema de procesamiento de lenguaje (NLP), sino a un desafío de extracción de conocimiento crítico bajo incertidumbre.

El sistema debe ser capaz de transformar la variabilidad del lenguaje humano en un conjunto discreto de variables que puedan someterse a auditoría. Como se detallará en posteriores secciones al analizar los perfiles de usuario, el diálogo natural implica convivir con información incompleta, datos irrelevantes y reformulaciones constantes. Salvar esta brecha es el principal requerimiento que justifica la investigación y el diseño del presente trabajo.

## 2.2. Marco Regulatorio Específico del Sector Financiero

Los requisitos generales de transparencia, trazabilidad, supervisión y gestión del riesgo aplicables a los sistemas de inteligencia artificial han sido analizados en el capítulo anterior. En el contexto de la concesión de crédito, estos principios adquieren una dimensión adicional debido a la naturaleza regulada de la actividad financiera y, especialmente, a las obligaciones relativas a la evaluación de la solvencia del solicitante.

En consecuencia, el problema no consiste únicamente en garantizar que el sistema conversacional sea trazable o supervisable, sino en asegurar que la información obtenida durante la interacción permita realizar una evaluación de crédito conforme a criterios financieros verificables y a las fuentes de información que resulten aplicables. Esto introduce requisitos específicos que condicionan directamente el diseño del sistema.

### 2.2.1. Evaluación de la solvencia

La normativa europea sobre crédito establece la obligación de realizar una evaluación adecuada de la solvencia antes de formalizar determinadas operaciones de crédito. En particular, la Directiva 2014/17/UE, aplicable al crédito relativo a bienes inmuebles de uso residencial, exige que la evaluación se realice sobre procedimientos e información establecidos y documentados. Por su parte, la Directiva (UE) 2023/2225, relativa a los contratos de crédito al consumo, establece que la evaluación debe realizarse en interés del consumidor y sobre información pertinente y exacta relativa a sus ingresos, gastos y demás circunstancias económicas relevantes.

Esta exigencia tiene una consecuencia directa para un sistema conversacional de concesión de crédito: los datos proporcionados durante el diálogo no pueden considerarse automáticamente equivalentes a datos financieros validados. El asistente puede encargarse de obtener y estructurar información como ingresos, gastos, deudas, importe solicitado o plazo, pero dicha información debe someterse a los mecanismos de validación y comprobación que correspondan antes de utilizarse como base de una decisión crediticia.

La normativa contempla además el uso de información procedente de fuentes internas y externas y, cuando resulte aplicable, de bases de datos relevantes para la evaluación de la solvencia. La Directiva (UE) 2023/2225 establece asimismo requisitos relativos a estas bases de datos y a la información que debe facilitarse al consumidor cuando una solicitud es rechazada como consecuencia de una consulta a dichas fuentes. Por tanto, el sistema debe ser capaz de distinguir entre la información declarada directamente por el solicitante, la información obtenida de fuentes externas y el resultado de las comprobaciones realizadas sobre ambas.

La decisión crediticia no debe depender exclusivamente de la interpretación probabilística de la conversación, sino de un conjunto estructurado de datos cuyo origen, estado de validación y utilización en la evaluación puedan determinarse de forma explícita.

### 2.2.2. Resiliencia operativa (DORA)

El Reglamento (UE) 2022/2554, conocido como Digital Operational Resilience Act (DORA), establece requisitos específicos para la gestión del riesgo asociado a las tecnologías de la información. Entre otros aspectos, exige disponer de un marco documentado de gestión del riesgo TIC y de mecanismos destinados a garantizar la resiliencia de los sistemas, la detección y gestión de incidentes y la capacidad de mantener las operaciones ante situaciones adversas.

En un sistema de concesión de crédito basado en un agente conversacional, estas obligaciones adquieren relevancia porque el componente de inteligencia artificial forma parte de un proceso financiero que no puede quedar condicionado exclusivamente por el comportamiento probabilístico del modelo generativo. El modelo puede participar en la comprensión de las respuestas del usuario y en la generación del diálogo, pero no debería constituir por sí mismo la autoridad sobre los datos financieros, las reglas de evaluación o el resultado final de la solicitud.

Esta separación no constituye una prohibición normativa de utilizar modelos generativos ni implica que DORA exija una arquitectura determinista. Se trata de una decisión derivada de la necesidad de controlar el riesgo tecnológico: las funciones críticas del proceso deben permanecer sometidas a mecanismos verificables y controlados, de manera que un error de interpretación, una respuesta generada incorrectamente o una entrada maliciosa no pueda modificar por sí misma los criterios financieros utilizados para evaluar la solicitud.

### 2.2.3. Implicaciones del EU AI Act para el crédito

El Reglamento (UE) 2024/1689, conocido como EU AI Act, establece un régimen específico para determinados sistemas de IA utilizados en la evaluación de la solvencia o en la determinación de la calificación crediticia de personas físicas. Estos sistemas aparecen incluidos entre los usos de alto riesgo recogidos en el Anexo III, con las condiciones y excepciones previstas por el propio Reglamento.

Por ello, el sistema desarrollado en este trabajo no debe limitar el registro a la respuesta final proporcionada al usuario. Debe conservar un estado estructurado de la solicitud y los eventos relevantes del proceso: datos proporcionados, datos validados, consultas a fuentes externas cuando procedan, resultados obtenidos, reglas de negocio aplicadas y resultado de la evaluación. El Reglamento exige capacidades de registro y establece requisitos de trazabilidad que permitan supervisar su funcionamiento.

En conjunto, la regulación específica del crédito desplaza el problema desde la simple interacción conversacional hacia la fiabilidad de la información utilizada para evaluar la solicitud. El asistente debe ser capaz de recopilar información de forma estructurada, distinguir su procedencia y grado de validación, incorporar fuentes externas cuando corresponda y someter el resultado a reglas financieras explícitas.

## 2.3. Modelado del Dominio y Ontología Financiera

Para que un sistema automatizado cumpla con las exigencias expuestas, el diálogo conversacional debe actuar exclusivamente como la interfaz para poblar un modelo de datos estructurado y determinista. Este modelo, conocido en la ingeniería del conocimiento como ontología, proporciona la arquitectura semántica que permite al sistema "comprender" el entorno bancario.

El modelado del dominio define los conceptos formales que componen el proceso de originación de crédito, sus atributos y las dependencias lógicas entre ellos. Esta estructura establece un estado canónico que actúa como única fuente de verdad durante el análisis de riesgo.

### 2.3.1. Entidades del Ecosistema Bancario

La ontología de un proceso de concesión de crédito requiere la conceptualización de múltiples entidades abstractas:

- **Cliente (Titular):** Representa a la persona física que inicia el proceso. El cliente es el nodo central del que dependen entidades subordinadas como su *Situación Económica* y sus *Obligaciones Financieras*.
- **Solicitud:** Actúa como la entidad contenedora (el expediente). Agrupa al titular, el producto deseado y el estado temporal de la operación (en curso, pendiente de validación, aprobada o denegada), garantizando la integridad transaccional.
- **Producto Financiero:** Define las características exactas del crédito que se está negociando. Sus parámetros definitorios incluyen el importe, la finalidad de la financiación, el plazo de amortización y el tipo de interés aplicable.
- **Situación Económica:** Entidad que modela la capacidad de generación de recursos del titular. Separa conceptualmente los ingresos recurrentes (nóminas, pensiones) de los esporádicos, y categoriza la estabilidad del vínculo laboral (tipo de contrato, antigüedad).
- **Obligaciones Financieras:** Representa el pasivo del cliente. Incluye préstamos vigentes, límites de tarjetas de crédito y otras cargas estructurales que impactan directamente en la liquidez disponible.

- **Avalista (Garante):** Entidad opcional que mitiga el riesgo de la operación. Replica la estructura del *Cliente*, requiriendo una instanciación paralela de su propia situación económica para evaluar su capacidad de respaldo.
- **Evaluación de Riesgo:** Es la entidad resultante. Almacena la resolución algorítmica, los umbrales financieros calculados y la traza de auditoría que justifica legalmente la decisión final.

### 2.3.2. Variables y Atributos de Riesgo

De cada una de las entidades descritas emana un conjunto de variables granulares que nutren los algoritmos de *scoring*. Estas variables se clasifican en cuatro dimensiones fundamentales de riesgo:

1. **Factores Personales y Sociodemográficos:** Atributos como la edad del solicitante y el número de personas a cargo, indispensables para calcular el umbral de subsistencia o mínimo inembargable.
2. **Capacidad de Pago:** Variables que cuantifican la liquidez, como los ingresos netos recurrentes. A nivel de riesgo bancario, un mismo volumen de ingresos recibe ponderaciones radicalmente distintas dependiendo de la categoría laboral (funcionario, trabajador indefinido o autónomo).
3. **Endeudamiento y Cargas:** Cifras necesarias para calcular el ratio de endeudamiento. Se compone de la suma de todas las cuotas mensuales vigentes más una estimación paramétrica de los gastos estructurales.
4. **Garantías:** Atributos de los activos o respaldos patrimoniales que aseguran la operación en caso de insolvencia.

El mayor desafío sistémico en este nivel es la **normalización de la información**. El lenguaje humano es inherentemente difuso. Si un solicitante declara "*gano unos mil quinientos, pero en catorce pagas*", el sistema no puede almacenar una transcripción literal. Debe poseer la capacidad de realizar una normalización semántica, traduciendo la expresión a variables tipadas y estrictas (ej. ingresos anualizados, divididos en doce meses). Sin esta cristalización de conceptos abstractos en tipos de datos estructurados, la evaluación matemática del riesgo resulta inviable.

### 2.3.3. Fuentes de Información

En cumplimiento de los principios de préstamo responsable, la información verbalizada por el solicitante carece de validez ejecutiva hasta ser contrastada. Todo sistema de evaluación debe basar su decisión en información verificada. Para ello, el modelado del dominio contempla la integración con repositorios externos e internos:

- **Central de Información de Riesgos (CIRBE):** Inventario público que acumula el historial crediticio y la exposición total al riesgo de las personas físicas. Su consulta permite aflorar pasivos vigentes que el usuario haya podido omitir involuntaria o deliberadamente.
- **Ficheros de Morosidad (ASNEF, BADEXCUG):** Registros de incumplimientos de obligaciones dinerarias. En el ámbito bancario, una coincidencia positiva en estos registros suele constituir un criterio de exclusión automática, invalidando cualquier capacidad de pago teórica demostrada previamente.
- **Bases de Datos Internas y Agregación Financiera:** Información transaccional histórica del banco o datos extraídos mediante normativas de *Open Banking* (PSD2), que permiten certificar la veracidad de los ingresos y gastos declarados.

El modelo de datos debe mantener un estatus de procedencia estricto, diferenciando siempre si un atributo (como la cuota de un préstamo existente) es un dato "declarado" por el usuario o un dato "verificado" por una de estas fuentes, garantizando la trazabilidad ante futuras auditorías.

### 2.3.4. Gestión de la Incertidumbre

Una diferencia relevante entre la originación de crédito mediante formularios tradicionales y las interfaces conversacionales reside en la forma en que se recopila y actualiza la información. Mientras que los formularios organizan los datos en campos explícitos, las interfaces conversacionales los obtienen progresivamente a lo largo de múltiples turnos. En consecuencia, durante buena parte de la interacción, el sistema debe operar con un expediente cuya información todavía puede estar incompleta, ser ambigua o presentar inconsistencias.

Esta característica exige que la arquitectura gestione el conocimiento parcial y evite que la ausencia de información se interprete como un valor válido

o como evidencia suficiente para tomar una decisión. El tratamiento del conocimiento parcial en el dominio crediticio exige distinguir tres situaciones principales:

1. **Información ausente:** Se produce cuando una variable requerida todavía no ha sido proporcionada ni obtenida mediante una fuente válida. Por ejemplo, si se desconocen los gastos mensuales del solicitante y estos son necesarios para evaluar su capacidad de pago, el sistema no debe sustituirlos por estimaciones. En su lugar, debe identificar el dato pendiente y solicitarlo al usuario o activar el mecanismo alternativo de obtención de información previsto por el proceso. La evaluación podrá continuar cuando se cumplan los requisitos de información establecidos para esa etapa.

2. **Información ambigua:** Aparece cuando una declaración no permite determinar de forma suficientemente precisa el valor o la categoría de una variable. Por ejemplo, afirmar que se tiene un "contrato normal" no permite establecer con certeza la modalidad contractual. El sistema debe identificar la ambigüedad y solicitar una aclaración cuando el dato sea relevante para la evaluación, hasta obtener un valor que pueda normalizarse y validarse conforme al modelo de dominio.

3. **Información inconsistente:** Se produce cuando existen contradicciones entre distintas declaraciones del usuario o discrepancias entre la información declarada y la obtenida de fuentes externas. Por ejemplo, el importe de las obligaciones financieras comunicado durante la conversación puede diferir del que consta en una fuente consultada, como la CIRBE, cuando dicha consulta resulte procedente. El sistema debe registrar la discrepancia y aplicar reglas explícitas para su tratamiento. Cuando la discrepancia sea relevante y no pueda resolverse mediante reglas previamente definidas, deberá solicitarse una aclaración o derivarse el expediente a revisión.

En síntesis, la gestión del conocimiento parcial convierte la evaluación crediticia conversacional en un proceso iterativo. A medida que avanza el diálogo, el sistema actualiza el expediente y comprueba si la información disponible satisface los requisitos de completitud, validez y coherencia establecidos para la siguiente etapa. Cuando estos requisitos se cumplen, el expediente puede pasar al catálogo de reglas de negocio de la entidad. En caso contrario, el sistema debe identificar qué información o validación sigue pendiente y determinar la acción correspondiente, sin confundir la ausencia de datos con el cumplimiento de los criterios de concesión.

## 2.4. Catálogo de Reglas en la Concesión de Crédito

Una vez definido el modelo de información necesario para representar una solicitud de crédito, es necesario establecer cómo dicha información se transforma en una decisión. En una entidad financiera, esta transformación no depende exclusivamente de un modelo estadístico o de la interpretación realizada por el sistema conversacional, sino de un conjunto de políticas, restricciones y criterios de decisión que determinan las condiciones bajo las cuales una operación puede ser concedida, rechazada o sometida a revisión.

Estas reglas constituyen el catálogo de reglas de negocio de la concesión de crédito. Su finalidad es formalizar los criterios aplicables a una solicitud de manera explícita y reproducible, separándolos de la lógica encargada de comprender el lenguaje natural del usuario.

Aunque las reglas concretas dependen de la entidad, del producto financiero y de su política de riesgos, conceptualmente pueden organizarse en diferentes capas de evaluación. En este trabajo se distinguen cuatro categorías:

### 2.4.1. Reglas de Elegibilidad Básica

Las reglas de elegibilidad determinan si una solicitud cumple las condiciones mínimas necesarias para continuar con el proceso de evaluación. Constituyen una primera capa de filtrado y suelen estar relacionadas con requisitos legales, características del producto o políticas generales de la entidad.

Entre los criterios que pueden formar parte de esta categoría se encuentran la edad del solicitante, las condiciones aplicables al plazo y vencimiento de la operación, el tipo de producto solicitado o determinadas restricciones relativas al destino de la financiación. También pueden existir condiciones relacionadas con la documentación o con la posibilidad de contratar el producto bajo unas determinadas circunstancias.

Su característica principal es que evalúan si la operación puede entrar o continuar en el proceso, antes de analizar en profundidad la capacidad económica y el perfil de riesgo del solicitante. Por tanto, una condición de elegibilidad incumplida puede impedir que tenga sentido continuar con las etapas posteriores de evaluación.

### 2.4.2. Reglas de Viabilidad Financiera

Superados los criterios básicos de elegibilidad, las reglas de viabilidad financiera permiten determinar si la situación económica del solicitante es compatible con las obligaciones derivadas de la nueva operación. El objetivo no es establecer todavía el riesgo global del cliente, sino evaluar su capacidad económica para asumir la financiación solicitada.

Estas reglas pueden combinar diferentes variables relacionadas con los ingresos, gastos, obligaciones financieras existentes, importe solicitado y condiciones de la nueva operación. Entre las métricas habituales se encuentran los ratios de endeudamiento, la relación entre ingresos y obligaciones financieras y el importe de renta disponible después de atender los compromisos previstos.

Una regla de este tipo puede, por ejemplo, comprobar que la cuota resultante de la nueva financiación, junto con las obligaciones financieras existentes, se mantiene dentro de los límites establecidos por la política de riesgos de la entidad. De forma complementaria, pueden establecerse umbrales mínimos de renta disponible que permitan evitar que el pago de las obligaciones financieras comprometa excesivamente la capacidad económica del solicitante.

Los valores concretos de estos límites no son universales, sino que dependen del producto, de la entidad y de su política de riesgos.

### 2.4.3. Reglas de Riesgo

La capacidad económica constituye una dimensión necesaria, pero no suficiente, para determinar la conveniencia de conceder una operación. Las reglas de riesgo incorporan información adicional relacionada con el historial de cumplimiento, la exposición crediticia y otras circunstancias que pueden modificar la valoración de una solicitud incluso cuando su capacidad de pago aparente ser suficiente.

Dentro de esta categoría pueden encontrarse reglas relacionadas con la existencia de obligaciones impagadas o incidencias registradas en fuentes de información crediticia. También pueden establecerse reglas para tratar situaciones en las que exista una discrepancia significativa entre la información declarada y la información obtenida mediante fuentes verificadas. Estas discrepancias no implican necesariamente una intención fraudulenta, ya que pueden deberse a errores de comunicación, información desactualizada o diferencias entre las definiciones utilizadas por distintas fuentes. Por este motivo, su tratamiento puede consistir en solicitar aclaraciones, requerir documentación adicional o derivar el expediente a revisión, en función de la política definida por la entidad.

La principal diferencia respecto a las reglas de viabilidad es, por tanto, que estas reglas no se limitan a responder si el cliente *puede* asumir matemáticamente la operación, sino que incorporan otros elementos relevantes para determinar si el nivel de riesgo asociado a dicha operación resulta aceptable para la entidad.

### 2.4.4. Reglas de Decisión y Resultados

Las reglas anteriores producen resultados parciales que deben ser consolidados para determinar el estado final de la solicitud. Esta última categoría establece cómo se combinan las diferentes evaluaciones y qué resultado corresponde a cada situación.

De forma general, pueden distinguirse tres resultados principales:

1. **Aprobación:** se produce cuando la solicitud satisface los criterios de elegibilidad y los resultados de las evaluaciones de capacidad y riesgo se encuentran dentro de los límites establecidos para la operación. En determinados productos y bajo las condiciones definidas por la entidad, este resultado puede producirse de forma automatizada.

2. **Denegación:** se produce cuando se incumple una condición que, de acuerdo con la política de la entidad, impide la concesión de la operación. El resultado debe estar asociado a los criterios que han conducido a dicha decisión, permitiendo reconstruir qué condiciones del expediente fueron determinantes.

3. **Revisión o intervención humana:** determinados expedientes pueden no encajar de forma inequívoca en las condiciones de aprobación o denegación automática. Esto puede ocurrir ante discrepancias relevantes, situaciones próximas a determinados umbrales o circunstancias que requieren una valoración adicional.

Esta separación permite distinguir entre las reglas que evalúan una determinada dimensión del expediente y las reglas que determinan cómo se consolida el resultado de dichas evaluaciones. El catálogo no constituye, por tanto, una única regla de concesión, sino un conjunto estructurado de criterios que, aplicados sobre un expediente suficientemente completo y validado, permiten obtener un resultado reproducible.

Desde la perspectiva de un sistema conversacional, esta separación resulta especialmente relevante. El modelo de lenguaje no debe determinar por sí mismo qué condiciones financieras son aceptables ni modificar los criterios de decisión en función de la conversación. Su función consiste en facilitar la

adquisición y estructuración de información, mientras que la aplicación de las reglas de negocio debe permanecer bajo mecanismos explícitos y controlables.

## 2.5. Perfiles de Usuario

La naturaleza conversacional introduce una alta variabilidad en la interacción, ya que puede recibir información completa y estructurada, datos incompletos o contradictorios, o incluso entradas diseñadas deliberadamente para alterar el comportamiento del sistema.

Por este motivo, el diseño del asistente no debe considerar únicamente el caso nominal de un usuario que proporciona correctamente toda la información solicitada. Es necesario contemplar diferentes perfiles de interacción que permitan identificar las situaciones que el sistema deberá gestionar durante la originación. Estos perfiles no representan necesariamente categorías de clientes reales, sino escenarios de interacción utilizados para analizar los requisitos funcionales y de seguridad del sistema.

### 2.5.1. Cliente con Información Completa

Representa el escenario nominal del proceso. El usuario conoce el producto que desea contratar, responde de forma coherente a las preguntas planteadas y proporciona la información necesaria para completar el expediente.

En este escenario, los datos relevantes pueden obtenerse progresivamente sin que aparezcan contradicciones significativas ni ambigüedades que requieran ciclos adicionales de aclaración.

Este escenario constituye el caso de referencia del sistema, pero no debe interpretarse como una garantía de aprobación. Que la interacción sea completa y fluida únicamente significa que no existen incidencias conversacionales que impidan realizar la evaluación. El resultado final seguirá dependiendo de los criterios de elegibilidad, capacidad financiera y riesgo definidos para la operación.

### 2.5.2. Cliente con Información No Declarada

En este escenario, la información proporcionada durante la conversación puede presentar inicialmente un perfil aparentemente compatible con la operación solicitada. Sin embargo, durante las fases posteriores de validación pueden aparecer circunstancias que no estaban presentes en la información declarada inicialmente.

Estas circunstancias pueden incluir obligaciones financieras no mencionadas durante la conversación, exposición crediticia indirecta o información procedente de fuentes externas que modifique la valoración de la solicitud. Por ejemplo, el solicitante puede declarar unos determinados niveles de endeudamiento mientras una fuente de información crediticia, cuando su consulta resulte procedente, revela obligaciones adicionales.

El escenario pone de manifiesto que la información conversacional no constituye necesariamente una representación completa del expediente. El sistema debe ser capaz de incorporar nueva información a medida que avanza el proceso y reevaluar el estado de la solicitud cuando aparecen datos que modifican las condiciones previamente consideradas.

La relevancia de este perfil no reside en asumir que la omisión de información sea deliberada. Una discrepancia puede deberse a desconocimiento, errores del usuario, diferencias temporales entre fuentes o una declaración intencionadamente incompleta. El sistema debe, por tanto, detectar y gestionar la discrepancia sin atribuir automáticamente una intención al solicitante.

### 2.5.3. Usuario Ambiguo o Errático

Este perfil representa una de las situaciones características de la interacción conversacional: el usuario no proporciona necesariamente la información requerida de manera ordenada ni en una única respuesta. Puede aportar datos fragmentados a lo largo de varios turnos, corregir respuestas anteriores, cambiar las condiciones de la operación o introducir información que no resulta relevante para la evaluación.

También pueden producirse contradicciones entre diferentes momentos de la conversación. Por ejemplo, el usuario puede declarar inicialmente unos ingresos y posteriormente proporcionar una cifra diferente, o modificar el importe solicitado después de que ya se hayan realizado determinados cálculos.

Este comportamiento impide tratar la conversación como una secuencia lineal de preguntas y respuestas independientes. El sistema debe mantener una representación persistente del estado de la solicitud y determinar en cada momento qué información se encuentra disponible, cuál ha sido corregida y qué datos continúan pendientes de validación.

### 2.5.4. Usuario Adversarial

El último escenario contempla interacciones en las que el usuario intenta deliberadamente modificar el comportamiento previsto del sistema o acceder a un resultado que no le correspondería según las reglas establecidas. A diferencia de los perfiles anteriores, el problema no procede de una interacción

imperfecta, sino de una posible intención de manipulación.

Estas amenazas pueden adoptar diferentes formas. En el plano social, un usuario podría intentar utilizar presión emocional, información falsa o técnicas de ingeniería social para conseguir que el sistema ignore determinadas restricciones o interprete favorablemente una situación de riesgo. En el plano técnico, pueden aparecer intentos de *prompt injection*, instrucciones introducidas dentro de la conversación para alterar las instrucciones operativas del sistema, modificar su comportamiento o conseguir que revele información que no debería proporcionar.

El sistema debe, por tanto, mantener una separación clara entre la interpretación de las entradas del usuario y la aplicación de las reglas que determinan la evaluación crediticia. La capacidad del modelo para comprender lenguaje natural no debe implicar que pueda modificar los criterios de decisión ni conceder al usuario control sobre el estado interno de la solicitud.

En conjunto, estos cuatro escenarios muestran que la dificultad del proceso conversacional no reside únicamente en obtener los datos necesarios para evaluar una solicitud, sino en mantener una representación coherente y controlada de dicha solicitud ante diferentes patrones de interacción. Desde el flujo nominal hasta las situaciones de inconsistencia o manipulación, el sistema debe preservar la integridad del proceso de evaluación independientemente de la forma en que el usuario interactúe con él.

## 2.6. Requisitos de Diseño Derivados del Dominio

El análisis del dominio financiero, sus restricciones regulatorias y los diferentes escenarios de interacción identificados en las secciones anteriores permiten derivar un conjunto de requisitos arquitectónicos específicos. El objetivo es determinar qué propiedades debe satisfacer cualquier solución que pretenda integrar un agente conversacional en un proceso de concesión de crédito sin delegar en el modelo generativo el control de la lógica financiera.

Estos requisitos se centran en tres aspectos fundamentales:

### 2.6.1. Necesidad de un Estado Canónico de la Solicitud

Como se ha observado al analizar los escenarios de interacción, la comunicación mediante lenguaje natural es incremental, fragmentada y susceptible de rectificaciones. Una misma variable puede aparecer en diferentes momentos de la conversación, ser modificada posteriormente o requerir validación mediante una fuente externa. Por este motivo, el historial de mensajes no

constituye por sí mismo una representación adecuada del estado financiero de la solicitud.

Se requiere una representación estructurada y persistente del estado de la solicitud que sea independiente del historial conversacional. En este trabajo, esta representación se denomina **Information State Update (ISU)** y se construye a partir del modelo de dominio definido anteriormente.

El ISU actúa como la fuente de verdad del proceso de evaluación, en él se almacenan los datos relevantes de la solicitud. De este modo, es posible distinguir entre un dato que todavía no ha sido proporcionado, uno declarado por el usuario y uno que ha sido posteriormente verificado mediante una fuente adicional.

Esto permite aplicar los mecanismos de gestión del conocimiento parcial descritos anteriormente y evita que la continuidad del proceso dependa exclusivamente de la capacidad del modelo de lenguaje para recuperar información del historial conversacional. Asimismo, permite que los diferentes componentes del sistema trabajen sobre una representación común y estructurada de la solicitud.

### 2.6.2. Separación entre Comprensión y Lógica

La necesidad de mantener bajo control las reglas que determinan la evaluación crediticia conduce a una segunda propiedad fundamental: la separación entre el procesamiento del lenguaje natural y la lógica de negocio.

El modelo generativo puede desempeñar funciones de comprensión y generación lingüística, como interpretar las respuestas del usuario, extraer información relevante o formular preguntas de seguimiento. Esta participación no supone que el modelo deba quedar excluido del tratamiento de los datos estructurados. Por ejemplo, ante una expresión como "quiero solicitar 1000 euros", el modelo puede identificar el importe solicitado y producir una representación estructurada como `importe_solicitado = 1000`. El dato puede incorporarse al estado de la solicitud como información declarada por el usuario, manteniendo su procedencia y naturaleza.

La separación de responsabilidades se establece en un nivel diferente: el modelo generativo no debe constituir la autoridad sobre la utilización financiera de esos datos. A partir del importe extraído, por ejemplo, no corresponde al modelo determinar si la cantidad es viable, calcular por sí mismo la capacidad de pago, consultar arbitrariamente una fuente de riesgo o decidir el resultado de la solicitud. Estas operaciones deben realizarse mediante componentes explícitos del sistema, de acuerdo con las reglas y procedimientos definidos para el dominio.

Las reglas de negocio, los cálculos financieros y las condiciones de decisión

deben permanecer, por tanto, en componentes cuya ejecución sea reproducible. Esto permite que un error de interpretación, una respuesta incorrecta o una instrucción de manipulación del lenguaje no pueda modificar directamente los criterios de concesión ni determinar por sí misma el resultado financiero. En particular, un intento de *prompt injection* no debería poder alterar una regla de negocio, modificar arbitrariamente el estado de la solicitud o convertir una instrucción proporcionada por el usuario en una decisión de concesión.

La frontera relevante no consiste, por tanto, en impedir que el modelo generativo participe en el tratamiento de la información, sino en delimitar sus responsabilidades. De este modo, la interpretación probabilística del lenguaje no constituye la autoridad final sobre la evaluación crediticia.

### 2.6.3. Trazabilidad y Auditabilidad de las Decisiones

El último requisito deriva de la necesidad de poder reconstruir el proceso mediante el cual una solicitud alcanza un determinado resultado. En un sistema de concesión de crédito, no resulta suficiente conservar únicamente la respuesta final mostrada al usuario. También debe ser posible determinar qué información estaba disponible, qué validaciones se realizaron y qué reglas intervinieron en la evaluación.

Por ello, el sistema debe disponer de mecanismos de registro que permitan conservar los eventos relevantes del proceso y protegerlos frente a modificaciones no autorizadas. Este registro debe complementar al estado actual de la solicitud, manteniendo el historial necesario para reconstruir la evolución del expediente.

Para cada decisión relevante, la traza debería permitir relacionar, al menos, tres dimensiones:

1. **Datos utilizados:** valores empleados durante la evaluación, junto con su procedencia y estado de validación.

2. **Reglas y operaciones aplicadas:** criterios de negocio, cálculos y validaciones que intervinieron en la evaluación, incluyendo la versión de las reglas cuando resulte necesario para reproducir el resultado.

3. **Resultado y causa de la decisión:** estado alcanzado por la solicitud y condiciones que determinaron dicho resultado.

Esta estructura permite que la explicación de una decisión se construya a partir de información efectivamente registrada durante la ejecución, en lugar de solicitar al modelo generativo una justificación retrospectiva de un

resultado cuyo proceso interno no ha quedado documentado. La trazabilidad se convierte así en una propiedad del proceso de decisión y no únicamente de la respuesta conversacional.

En conjunto, los tres requisitos definidos delimitan las propiedades fundamentales que debe satisfacer la arquitectura propuesta. Estos requisitos permiten trasladar las características específicas del dominio crediticio a decisiones concretas de diseño, cuya implementación se desarrolla en los capítulos posteriores.